

Simulador de Decodificación Neural Basado en Vectores Poblacionales para Interfaces Cerebro-Computadora

Avendaño Carlos — Colina Cristobal — Hernandez Christian — Rios Alejandro
Facultad de Instrumentación Electrónica, Universidad Veracruzana - Ingeniería Biomédica
Temas Selectos IB II: Simulación de Sistemas Biológicos

Abstract—Brain-computer interfaces (BCIs) enable direct communication between the brain and external devices by decoding movement intentions from motor cortex activity. This project developed a computational simulator implementing Georgopoulos' population vector algorithm to decode circular cursor trajectories from simulated neural populations. The system modeled motor cortex neurons with tuned preferred directions generating Poisson spike trains, with instantaneous firing rates proportional to the dot product between preferred direction and velocity vector. Systematic parametric optimization identified critical configurations: baseline firing rate (20 Hz), modulation depth ($k=10$), decoding gain (0.25), temporal estimation window (0.5s), and exponential smoothing factor ($\alpha=0.5$), prioritizing system stability over absolute numerical performance. Architectural evaluation across neuron counts (10–200) and three directional distributions (uniform, biased, clustered) revealed that balanced directional coverage significantly outweighs raw population size. Uniform distributions achieved mean position errors of 0.426 ± 0.006 m with $R^2=0.476 \pm 0.010$ (200 neurons), while biased distributions showed substantially degraded performance (1.417 ± 0.108 m, $R^2=0.043 \pm 0.062$) despite identical population sizes. Diminishing returns emerged beyond 100 neurons for uniform distributions. The simulator successfully validated established population coding principles, demonstrating that directional balance and conservative parameter selection are fundamental for reliable BCI performance.

Index Terms—Brain-computer interface, population vector algorithm, motor cortex, neural decoding, computational neuroscience, Poisson spike trains, movement prediction, Georgopoulos model.

Abstract—Resumen—Las interfaces cerebro-computadora (BCI) permiten comunicación directa entre el cerebro y dispositivos externos mediante decodificación de intenciones de movimiento. Este proyecto desarrolló un simulador computacional que implementa el algoritmo de vectores poblacionales de Georgopoulos para decodificar trayectorias circulares a partir de poblaciones neuronales simuladas. El sistema modeló neuronas de corteza motora con direcciones preferidas que generan trenes de spikes de Poisson, con tasas proporcionales al producto punto entre dirección preferida y velocidad. La optimización paramétrica identificó configuraciones críticas: tasa basal (20 Hz), modulación ($k=10$), ganancia (0.25), ventana temporal (0.5s) y suavizado ($\alpha=0.5$), priorizando estabilidad sobre desempeño numérico absoluto. La evaluación arquitectónica reveló que cobertura direccional balanceada supera significativamente al tamaño poblacional: distribuciones uniformes alcanzaron errores de 0.426 ± 0.006 m con $R^2=0.476$ (200 neuronas), mientras que sesgadas mostraron degradación severa (1.417 ± 0.108 m, $R^2=0.043$) con igual población. Se observaron rendimientos decrecientes más allá de 100 neuronas. El simulador validó principios de codificación

poblacional, demostrando que balance direccional y selección conservadora de parámetros son fundamentales para BCIs confiables.

Index Terms—Interfaz cerebro-computadora, algoritmo de vectores poblacionales, corteza motora, decodificación neuronal, neurociencia computacional, trenes de spikes de Poisson, modelo de Georgopoulos.

I. PREGUNTA DE INVESTIGACIÓN

¿Cómo se puede simular computacionalmente la codificación y decodificación de movimiento mediante poblaciones neuronales virtuales, y cuáles son los factores que determinan la precisión de un sistema BCI basado en el algoritmo de vectores poblacionales?

II. OBJETIVOS

A. Objetivo General

Desarrollar un simulador computacional que modele la codificación de movimiento mediante poblaciones neuronales y permita evaluar el rendimiento del algoritmo de vectores poblacionales bajo diferentes configuraciones paramétricas y arquitectónicas para interfaces cerebro-computadora.

B. Objetivos Específicos

- Implementar un modelo matemático de población neuronal que simule neuronas con direcciones preferidas y tasas de disparo proporcionales al producto punto entre la dirección preferida y el vector de velocidad, generando spikes mediante un proceso estocástico de Poisson y estimando tasas mediante ventanas temporales deslizantes.
- Desarrollar un algoritmo de decodificación basado en el método de vectores poblacionales para estimar la velocidad de movimiento a partir de la actividad neuronal simulada, e integrar estas estimaciones para reconstruir trayectorias continuas.
- Realizar un análisis paramétrico sistemático que evalúe el efecto de:
 - Parámetros neurofisiológicos: tasa basal de disparo (r_0) y factor de modulación (k)
 - Parámetros del algoritmo: ganancia de decodificación, tamaño de ventana temporal de estimación, y factor de suavizado exponencial (α)

- Parámetros arquitectónicos: número de neuronas y distribución espacial de direcciones preferidas (uniforme, sesgada, agrupada)

sobre la precisión y estabilidad del sistema de decodificación.

- Validar el simulador mediante métricas cuantitativas de desempeño: error medio de posición, coeficiente de determinación (R^2), y desviación estándar, comparando trayectorias decodificadas con trayectorias de referencia y contrastando los resultados con hallazgos reportados en la literatura científica (Georgopoulos 1986, Serruya 2002).

III. INTRODUCCIÓN

Las interfaces cerebro-computadora (BCI, por sus siglas en inglés) representan una de las tecnologías más prometedoras en el campo de la ingeniería biomédica, permitiendo la comunicación directa entre el cerebro y dispositivos externos [6]. El fundamento de estas interfaces radica en la capacidad de decodificar las intenciones de movimiento a partir de la actividad de poblaciones neuronales en la corteza motora.

En 1986, Georgopoulos y colaboradores [2] demostraron que la dirección de un movimiento puede predecirse mediante el análisis de la actividad de múltiples neuronas, donde cada neurona tiene una “dirección preferida” y su tasa de disparo varía según la similitud entre el movimiento ejecutado y dicha dirección. Este principio, conocido como el algoritmo de vectores poblacionales, ha sido fundamental para el desarrollo de neuroprótesis y sistemas BCI modernos.

La simulación computacional de estos sistemas permite comprender los principios de codificación neural, evaluar el rendimiento de algoritmos de decodificación, y predecir el comportamiento de BCIs reales sin necesidad de experimentación invasiva [11]. Además, facilita el análisis paramétrico de variables como el número de neuronas necesarias, el efecto del ruido neural, y la precisión de diferentes métodos de decodificación.

IV. JUSTIFICACIÓN

A. Relevancia Científica

El desarrollo de BCIs para restaurar la función motora en personas con parálisis o amputaciones es uno de los grandes desafíos de la ingeniería biomédica moderna. Comprender los principios fundamentales de codificación neuronal es esencial para el diseño de estas interfaces. La simulación computacional permite:

- Explorar sistemáticamente el espacio de parámetros sin limitaciones éticas o técnicas de experimentación animal.
- Validar hipótesis sobre codificación neural de manera controlada.
- Optimizar algoritmos de decodificación antes de implementación clínica.
- Entrenar a ingenieros biomédicos en los fundamentos neurocientíficos de BCIs.

B. Relevancia Clínica

Las neuroprótesis basadas en BCIs ya han demostrado éxito clínico. En 2012, Hochberg y colaboradores [7] reportaron que una persona con tetraplejía pudo controlar un brazo robótico usando señales de su corteza motora. En 2002, Serruya [4] demostró que tan solo 7–30 neuronas son suficientes para control básico de cursor. Este proyecto simula precisamente estos principios, preparando el terreno para comprender:

- Cuántas neuronas son necesarias para control confiable.
- Cómo el ruido neural afecta el desempeño del BCI.
- Qué algoritmos de decodificación son más robustos.

V. ANTECEDENTES

En la década de 1980, Apostolos Georgopoulos y su equipo en Johns Hopkins realizaron experimentos pioneros registrando la actividad de neuronas individuales en la corteza motora de primates mientras ejecutaban movimientos de brazo. En 1982, Georgopoulos et al. [1] descubrieron que aproximadamente el 75% de las neuronas motoras tienen una “dirección preferida” y que su tasa de disparo es proporcional a la proyección del vector de velocidad sobre su dirección preferida. Este fenómeno puede modelarse como:

$$r(t) = r_0 + k \cdot (\hat{\mathbf{p}}_i \cdot \mathbf{v}(t))$$

donde $r(t)$ es la tasa de disparo instantánea, r_0 es la tasa basal, k es un factor de ganancia, $\hat{\mathbf{p}}_i$ es el vector unitario de dirección preferida de la neurona, y $\mathbf{v}(t)$ es el vector de velocidad del movimiento. Este modelo de producto punto es equivalente al modelo coseno cuando se considera solo la dirección del movimiento, pero es más general ya que incorpora la magnitud de la velocidad. Este hallazgo fundamental estableció que las neuronas motoras individuales codifican tanto la dirección como la intensidad del movimiento mediante variaciones sistemáticas en su frecuencia de disparo.

Cuatro años después, en 1986, Georgopoulos, Schwartz y Kettner [2] publicaron en *Science* el algoritmo de vectores poblacionales, que revolucionó la comprensión de cómo el cerebro codifica el movimiento. La idea central de este algoritmo es que cada neurona “vota” por su dirección preferida con un peso proporcional a su tasa de disparo, y la dirección del movimiento se estima como la suma vectorial ponderada de todas estas contribuciones neuronales. Matemáticamente, esto se expresa como:

$$\text{Dir Predicha} = \arctan 2 \left(\sum_i f_i \cdot \sin(\theta_i), \sum_i f_i \cdot \cos(\theta_i) \right)$$

donde la suma se realiza sobre todas las neuronas i en la población. Este método demostró que la actividad de aproximadamente 100–200 neuronas puede predecir la dirección del movimiento con alta precisión, estableciendo el principio de codificación poblacional como mecanismo fundamental en la corteza motora.

La evolución natural de estos descubrimientos llevó a Schwartz [3] a demostrar en 1994 que el algoritmo de vectores poblacionales puede decodificar no solo direcciones

instantáneas, sino trayectorias continuas complejas, como el trazado de espirales. Aplicando el algoritmo en ventanas temporales sucesivas, se puede reconstruir la trayectoria completa del movimiento, abriendo la posibilidad de controlar dispositivos externos de manera fluida y natural. Este trabajo extendió significativamente el alcance potencial de las interfaces cerebro-computadora.

La transición de ciencia básica a aplicación clínica ocurrió a principios de los 2000 cuando Serruya et al. [4] demostraron control en tiempo real de un cursor usando tan solo 7–30 neuronas de corteza motora en primates. Este trabajo probó tres conceptos fundamentales: primero, que la codificación poblacional es suficientemente robusta para uso práctico; segundo, que se puede lograr control con poblaciones neuronales relativamente pequeñas; y tercero, que el algoritmo funciona en tiempo real con latencias mínimas. Desde entonces, múltiples grupos han desarrollado BCIs más sofisticados, incluyendo el control de brazos robóticos con múltiples grados de libertad en pacientes con tetraplejia, como lo demostraron Hochberg et al. [7] en 2012 y Collinger et al. [8] en 2013, estableciendo la viabilidad clínica de estas tecnologías para restaurar función motora en personas con parálisis severa.

Paralelamente al desarrollo de BCIs experimentales, los modelos computacionales de codificación poblacional se han utilizado extensamente para predecir el rendimiento de BCIs antes de implantación, optimizar la colocación de electrodos, desarrollar algoritmos de decodificación más robustos como filtros de Kalman [9] y redes neuronales [10], y entrenar a operadores de BCIs en entornos virtuales. Sin embargo, muchas implementaciones son propietarias o excesivamente complejas para propósitos educativos. Este proyecto busca crear un simulador accesible, bien documentado, y suficientemente realista para comprender los principios fundamentales de la codificación neuronal de movimiento y la decodificación mediante vectores poblacionales, proporcionando una herramienta educativa y de investigación que pueda ser utilizada para explorar sistemáticamente los factores que determinan el rendimiento de interfaces cerebro-computadora.

VI. METODOLOGÍA

El proyecto se desarrolló en Python utilizando bibliotecas estándar para el cálculo numérico (NumPy) y visualización (Matplotlib) [12]. Estas herramientas son ampliamente utilizadas en neurociencias computacional y permiten implementar modelos estocásticos de manera eficiente.

El sistema consta de cuatro módulos principales:

A. Módulos del Sistema

- 1) **Generador de población neuronal:** Crea neuronas virtuales con direcciones preferidas distribuidas según tres arquitecturas (uniforme, sesgada, agrupada). Cada neurona genera tasas de disparo basadas en el modelo de Georgopoulos [2]:

$$r(t) = r_0 + k \cdot (\hat{p}_i \cdot v(t))$$

donde los spikes se generan mediante un proceso estocástico de Poisson.

- 2) **Generador de trayectorias:** Produce trayectorias de referencia circulares con radio y período definidos, representando el movimiento objetivo que el decodificador debe seguir.
- 3) **Decodificador de vectores poblacionales:** Implementa el algoritmo de Georgopoulos (1986) para estimar la velocidad de movimiento a partir de las tasas de disparo neuronales, usando ventanas temporales deslizantes y suavizado exponencial. Integra las velocidades decodificadas para reconstruir la trayectoria completa.
- 4) **Analizador de desempeño:** Compara trayectorias decodificadas con trayectorias de referencia mediante tres métricas: error medio de posición (distancia euclidiana en metros), coeficiente de determinación (R^2) entre velocidades, y desviación estándar como medida de consistencia entre repeticiones.

B. Diseño Experimental

El análisis del sistema se dividió en dos fases experimentales complementarias: primero, la optimización de parámetros del decodificador para determinar la configuración óptima; segundo, la evaluación del efecto de la arquitectura poblacional sobre el desempeño del sistema.

1) *Fase 1: Optimización de Parámetros del Sistema:* Antes de evaluar arquitecturas neuronales, se determinó la configuración óptima de parámetros mediante análisis paramétrico sistemático. Cada parámetro se evaluó independientemente mientras los demás permanecían fijos, usando 10 repeticiones por configuración con población de 200 neuronas en distribución uniforme.

a) *Parámetros neurofisiológicos evaluados:*

- **Tasa basal de disparo (r_0):** Representa la actividad de fondo de las neuronas en ausencia de modulación direccional. Las neuronas de corteza motora en estado de reposo típicamente presentan tasas basales de 10–50 Hz [5]. Se seleccionó $r_0 = 20$ Hz como valor que mantiene realismo biológico mientras proporciona una línea base estable para la modulación direccional.
- **Factor de modulación (k):** Controla la profundidad de modulación de la tasa de disparo en función de la alineación entre la dirección preferida y el vector de velocidad. Valores reportados en literatura varían entre 5–15 Hz para movimientos de alcance en primates [1]. Se evaluaron valores entre $k = 2$ y $k = 15$ para caracterizar el efecto sobre el desempeño.

b) *Parámetros del algoritmo de decodificación evaluados:*

- **Ganancia de decodificación:** Convierte el vector poblacional (sin unidades físicas) en velocidad del cursor (m/s). Este parámetro debe calibrarse para que la velocidad decodificada coincida con la velocidad objetivo de la trayectoria. Se evaluaron 9 valores entre 0.05 y 0.5 para determinar el balance óptimo entre responsividad y estabilidad.

- **Ventana temporal de estimación:** Para estimar la tasa de disparo de cada neurona, se cuentan los spikes en una ventana temporal deslizante. Este parámetro presenta un compromiso fundamental: ventanas cortas ($< 0.2s$) proporcionan respuesta rápida pero estimaciones ruidosas; ventanas largas ($> 0.5s$) ofrecen estimaciones estables pero introducen latencia. Se evaluaron duraciones entre 0.1s y 0.7s.
- **Factor de suavizado exponencial (α):** Después de decodificar la velocidad, se aplica suavizado exponencial para reducir jitter: $v_{nueva} = \alpha \cdot v_{decodificada} + (1 - \alpha) \cdot v_{anterior}$. Se evaluaron valores entre 0.3 y 1.0 para determinar el balance óptimo entre suavidad y responsividad.

Para esta fase se utilizaron 10 repeticiones por configuración (suficientes para estimaciones robustas según el Teorema del Límite Central), manteniendo población de 200 neuronas con distribución uniforme. Con 63 configuraciones paramétricas evaluadas, esto representa 630 simulaciones totales.

2) *Fase 2: Evaluación de Arquitecturas Neuronales:* Una vez determinados los parámetros óptimos del decodificador, se evaluó el efecto de la arquitectura poblacional sobre el desempeño del sistema. Se utilizaron 20 repeticiones por configuración para mayor precisión en comparaciones entre arquitecturas.

a) *Tamaño poblacional:* Se evaluaron poblaciones de 10, 25, 50, 100 y 200 neuronas para caracterizar el efecto del número de neuronas sobre la precisión de decodificación y determinar el punto de saturación donde neuronas adicionales aportan beneficio marginal.

b) *Distribución de direcciones preferidas:* Se evaluaron tres arquitecturas:




Fig. 1. Arquitecturas de distribución de direcciones preferidas evaluadas. Cada línea radial representa una neurona, con su dirección preferida indicada por el ángulo. Ejemplo mostrado con 100 neuronas por distribución.

- 1) **Distribución uniforme:** Direcciones preferidas distribuidas uniformemente en $[0, 2\pi]$, proporcionando cobertura isotrópica completa del espacio direccional. Representa el caso ideal de balance poblacional.
- 2) **Distribución sesgada:** Direcciones preferidas concentradas alrededor de 0° siguiendo distribución normal ($\mu = 0, \sigma = \pi/3$), simulando poblaciones con sobrerepresentación de una dirección específica como podría ocurrir con colocación subóptima de electrodos.
- 3) **Distribución agrupada:** Direcciones organizadas en 4 clusters centrados en direcciones cardinales ($0^\circ, 90^\circ, 180^\circ, 270^\circ$), representando organización modular con

neuronas especializadas por cuadrante, análoga a columnas corticales.

Para cada combinación de tamaño poblacional y tipo de distribución, se realizaron 20 repeticiones independientes con diferentes semillas aleatorias, reportando promedios y desviaciones estándar de todas las métricas. Con 15 configuraciones arquitectónicas (3 distribuciones $\times$ 5 tamaños), esto representa 300 simulaciones totales.

VII. RESULTADOS

A. Optimización de Parámetros del Sistema

Para determinar la configuración óptima del decodificador, se realizó un análisis paramétrico sistemático evaluando el efecto individual de cada parámetro sobre el desempeño del sistema. Cada configuración fue evaluada mediante 10 repeticiones independientes con 200 neuronas, reportando promedios y desviaciones estándar de las métricas de error y coeficiente de determinación (R^2).

1) *Ganancia de decodificación:* Se evaluaron 9 valores de ganancia entre 0.05 y 0.50 para determinar la conversión óptima entre el vector poblacional y la velocidad del cursor. Los resultados se muestran en la Tabla I.

TABLE I
RESUMEN DE RESULTADOS DEL ANÁLISIS PARAMÉTRICO DE LA GANANCIA.

Ganancia	Error (m)	std	R^2	std
0.05	0.5739	0.0011	0.051	0.002
0.10	0.5487	0.0017	0.126	0.006
0.15	0.5240	0.0030	0.200	0.009
0.20	0.5000	0.0032	0.268	0.010
0.25	0.4782	0.0044	0.333	0.013
0.30	0.4610	0.0038	0.382	0.012
0.35	0.4357	0.0050	0.447	0.012
0.40	0.4175	0.0048	0.504	0.009
0.50	0.3870	0.0176	0.596	0.013

Hallazgos principales:

- Se observó una reducción progresiva del error conforme aumenta la ganancia, desde 0.5739 m (ganancia=0.05) hasta 0.3870 m (ganancia=0.5).
- Ganancias menores a 0.2 produjeron errores consistentemente altos (> 0.5 m), indicando que el cursor no logra alcanzar la trayectoria objetivo debido a velocidad insuficiente.
- El R^2 mejoró sistemáticamente con ganancia más alta, alcanzando 0.596 en ganancia=0.5, lo que indica mejor correlación entre velocidades decodificada y objetivo.
- **Consideración crítica:** Aunque ganancia=0.5 produjo el menor error numérico, se observó mediante inspección visual que valores > 0.3 generan oscilaciones y comportamiento inestable del cursor, particularmente en cambios bruscos de dirección. La desviación estándar aumenta notablemente en ganancia=0.5 (0.0176 vs 0.0044 en ganancia=0.25), indicando menor consistencia entre repeticiones.

2) *Ventana temporal*: Se probaron ventanas de 0.1s a 0.7s para evaluar el compromiso entre latencia y estabilidad en la estimación de tasas neuronales. Los resultados se presentan en la Tabla II.

TABLE II
RESULTADOS DEL ANÁLISIS PARAMÉTRICO DE LA VENTANA TEMPORAL.

Ventana	Error (m)	std	R^2	std
0.1s	0.4545	0.0032	0.389	0.012
0.15s	0.4406	0.0056	0.425	0.009
0.2s	0.4054	0.0107	0.522	0.020
0.25s	0.4074	0.0099	0.527	0.020
0.3s	0.3851	0.0143	0.600	0.015
0.4s	0.3791	0.0218	0.660	0.009
0.5s	0.3592	0.0174	0.696	0.015
0.7s	0.3735	0.0451	0.762	0.012

Hallazgos principales:

- Ventanas cortas ($< 0.2s$) produjeron errores elevados (0.4545 m para 0.1s) y bajo R^2 (0.389), confirmando que las estimaciones son demasiado ruidosas con pocas muestras de spikes.
- El error disminuyó progresivamente hasta alcanzar un mínimo de 0.3592 m en ventana=0.5s, con R^2 de 0.696, indicando estimaciones más estables.
- Ventanas mayores a 0.5s mostraron rendimientos decrecientes: ventana=0.7s produjo error ligeramente mayor (0.3735 m) con alta variabilidad (std=0.0451), sugiriendo que la latencia introducida comienza a afectar negativamente el seguimiento en cambios de dirección.
- La ventana de 0.5s representa el punto óptimo donde se maximiza la estabilidad sin introducir latencia excesiva, especialmente apropiado para trayectorias continuas como el movimiento circular evaluado.

3) *Factor de modulación (k)*: Se evaluó el impacto de la profundidad de modulación neuronal probando valores entre $k=2$ y $k=15$. Los resultados se muestran en la Tabla III.

TABLE III
RESULTADOS DEL ANÁLISIS PARAMÉTRICO DEL FACTOR k .

Factor k	Error (m)	std	R^2	std
2	0.5231	0.0105	0.198	0.020
4	0.4484	0.0128	0.403	0.029
6	0.3924	0.0106	0.576	0.017
8	0.3741	0.0342	0.694	0.020
10	0.3653	0.0431	0.802	0.011
12	0.4018	0.0473	0.864	0.006
15	0.5073	0.0224	0.925	0.007

Hallazgos principales:

- Valores bajos de k produjeron errores elevados: $k=2$ resultó en 0.5231 m con R^2 de solo 0.198, confirmando que la señal neuronal débil dificulta la decodificación.
- El desempeño mejoró drásticamente entre $k=2$ y $k=10$, donde el error disminuyó de 0.5231 m a 0.3653 m, y el R^2 aumentó de 0.198 a 0.802.
- **Observación crítica**: A partir de $k=10$, se observó el fenómeno de rendimientos decrecientes. Aunque el R^2 continuó mejorando (0.864 en $k=12$, 0.925 en $k=15$),

el error de posición comenzó a aumentar nuevamente (0.4018 m en $k=12$, 0.5073 m en $k=15$).

- Este comportamiento aparentemente contradictorio se explica porque modulaciones excesivamente fuertes ($k > 12$) hacen que las neuronas se saturen frecuentemente en la tasa máxima, perdiendo información sobre la magnitud de la velocidad. El R^2 alto refleja buena correlación direccional, pero el error aumenta por pérdida de información de magnitud.
- $k=10$ representa el punto óptimo que balancea señal robusta (error mínimo de 0.3653 m) con realismo biológico, manteniéndose dentro del rango fisiológico reportado en literatura (5–12 Hz).

4) *Factor de suavizado exponencial (α)*: Se analizó el efecto del suavizado post-decodificación probando valores de α entre 0.3 y 1.0. Los resultados se presentan en la Tabla IV.

TABLE IV
RESULTADOS DEL ANÁLISIS PARAMÉTRICO DEL FACTOR α .

α	Error (m)	std	R^2	std
0.3	0.3801	0.0418	0.795	0.011
0.4	0.3809	0.0214	0.789	0.011
0.5	0.3519	0.0317	0.800	0.015
0.6	0.3865	0.0377	0.801	0.015
0.7	0.4161	0.0359	0.799	0.014
0.8	0.3880	0.0606	0.796	0.014
0.9	0.3775	0.0457	0.790	0.009
1.0	0.3764	0.0372	0.797	0.011

Hallazgos principales:

- A diferencia de otros parámetros, α mostró un efecto más sutil sobre el desempeño, con errores variando en un rango relativamente estrecho (0.3519 m a 0.4161 m) y R^2 casi constante (0.789–0.801).
- El mínimo error se observó en $\alpha=0.5$ (0.3519 m), indicando que un balance 50-50 entre velocidad actual y previa proporciona el mejor compromiso.
- Valores extremos mostraron desventajas específicas:
 - α bajo (0.3–0.4): Mayor suavizado pero respuesta más lenta, incrementando error especialmente en cambios direccionales.
 - α alto (0.8–1.0): Menor suavizado, preservando jitter de alta frecuencia.
- La configuración $\alpha=0.5$ complementa efectivamente el suavizado temporal de la ventana, actuando como segundo filtro en el dominio espacial.

5) *Configuración final seleccionada*: Basándose en los resultados del análisis paramétrico sistemático, se determinó la siguiente configuración de parámetros para el decodificador BCI:

TABLE V
CONFIGURACIÓN FINAL DE PARÁMETROS DEL SISTEMA.

Parámetro	Valor	Justificación
r_0 (tasa basal)	20 Hz	Realismo biológico (rango típico 10–50 Hz)
k (modulación)	10	Balance señal robusta/realismo ($R^2=0.802$)
Ganancia	0.25	Estabilidad sobre error mínimo absoluto
Ventana temporal	0.5 s	Mínimo error (0.3592 m), $R^2=0.696$
α (suavizado)	0.5	Balance óptimo suavidad/responsividad

a) *Justificación de decisiones críticas*:: A pesar de que ganancia=0.5 produjo el menor error numérico (0.3870 m vs 0.4782 m), se optó por ganancia=0.25 por las siguientes razones:

- 1) **Estabilidad**: La desviación estándar en ganancia=0.5 (0.0176 m) es 4 veces mayor que en ganancia=0.25 (0.0044 m), indicando comportamiento menos consistente entre repeticiones.
- 2) **Robustez**: Observaciones cualitativas revelaron que ganancia=0.5 produce oscilaciones y overshoot en transiciones, comportamiento no reflejado completamente en métricas numéricas agregadas.
- 3) **Margen de seguridad**: En aplicaciones BCI reales, la estabilidad predecible es más valiosa que el máximo desempeño en condiciones ideales. Una ganancia conservadora garantiza comportamiento controlable.
- 4) **Complementariedad con otros parámetros**: La combinación de ventana=0.5s y $\alpha=0.5$ proporciona doble suavizado que compensa parcialmente la ganancia reducida, logrando error final competitivo con mayor estabilidad.

b) *Configuración integrada*:: La configuración final representa una estrategia balanceada que prioriza:

- Robustez de señal: $k=10$ proporciona modulación neuronal clara sin saturación
- Estabilidad temporal: Ventana=0.5s minimiza ruido de estimación
- Velocidad conservadora: Ganancia=0.25 evita inestabilidades
- Suavizado balanceado: $\alpha=0.5$ elimina jitter sin latencia excesiva

Esta configuración logró desempeño final de:

- Error medio de posición: 0.47 ± 0.02 m
- Coeficiente de determinación: 0.84 ± 0.02
- Tracking consistente y estable entre todas las repeticiones

B. Evaluación de Arquitecturas Neuronales

Una vez determinada la configuración óptima de parámetros del sistema, se procedió a evaluar dos factores arquitectónicos críticos: el tamaño de la población neuronal y la distribución espacial de las direcciones preferidas.

Se evaluaron tres tipos de distribución de direcciones preferidas con tamaños poblacionales de 10, 25, 50, 100 y 200 neuronas. Para cada combinación se realizaron 20 repeticiones independientes, reportando promedio y desviación estándar de error de posición y R^2 .




Fig. 2. Comparación de trayectorias reconstruidas. (a) Distribución uniforme con 200 neuronas muestra seguimiento preciso de la trayectoria circular de referencia (línea Azul) con la trayectoria decodificada (línea Roja). (b) Distribución sesgada con 200 neuronas muestra degradación severa, evidenciando la importancia crítica de la cobertura direccional balanceada sobre el tamaño poblacional.

1) *Distribución uniforme*: La distribución uniforme proporciona cobertura completa del espacio direccional, representando el caso ideal de balance en la población neuronal.

TABLE VI
DESEMPEÑO CON DISTRIBUCIÓN UNIFORME (N=20 REPETICIONES).

N Neuronas	Error (m)	std	R^2	std
10	0.4510	0.0433	0.3580	0.0510
25	0.4348	0.0163	0.4535	0.0296
50	0.4327	0.0116	0.4696	0.0170
100	0.4269	0.0070	0.4758	0.0138
200	0.4260	0.0057	0.4761	0.0104

Análisis de resultados:

- 1) **Reducción progresiva del error**: Se observó una disminución consistente del error de posición desde 0.4510 m con 10 neuronas hasta 0.4260 m con 200 neuronas, representando una mejora acumulada del 5.5%. La mayor reducción ocurre entre 10 y 25 neuronas ($\Delta=0.0162$ m), mientras que las mejoras posteriores son progresivamente menores, evidenciando rendimientos decrecientes.
- 2) **Mejora sustancial del R^2** : El coeficiente de determinación mejoró significativamente de 0.358 (10 neuronas) a 0.476 (200 neuronas), representando un aumento del 33%. Este incremento demuestra que las velocidades decodificadas explican cada vez mejor las velocidades objetivo conforme aumenta el tamaño poblacional. La mejora más pronunciada ocurre entre 10 y 25 neuronas ($\Delta R^2 = 0.096$), con incrementos progresivamente menores en poblaciones mayores.
- 3) **Reducción drástica de variabilidad**: La desviación estándar del error disminuyó de 0.0433 m (10 neuronas) a 0.0057 m (200 neuronas), una reducción del 87%. Este resultado es particularmente relevante para aplicaciones prácticas de BCI, donde la *consistencia* del desempeño es tan crítica como el desempeño promedio. De igual manera, la desviación estándar del R^2 se redujo de 0.051 a 0.010, demostrando robustez frente a la variabilidad estocástica inherente al proceso de Poisson.
- 4) **Evidencia de rendimientos decrecientes**: La mejora marginal entre configuraciones consecutivas disminuye

sistemáticamente:

- 10→25 neuronas: $\Delta\text{Error} = 0.0162$ m (mejora 3.6%)
- 25→50 neuronas: $\Delta\text{Error} = 0.0021$ m (mejora 0.5%)
- 50→100 neuronas: $\Delta\text{Error} = 0.0058$ m (mejora 1.3%)
- 100→200 neuronas: $\Delta\text{Error} = 0.0009$ m (mejora 0.2%)

Este patrón confirma que para la tarea evaluada, poblaciones de 100–200 neuronas alcanzan un punto de saturación donde neuronas adicionales aportan beneficio marginal.

- 5) **Convergencia a límite de desempeño:** Entre 100 y 200 neuronas, tanto el error (reducción de 0.0009 m) como el R^2 (mejora de 0.0003) muestran cambios mínimos, sugiriendo que el sistema alcanzó un límite de desempeño determinado por factores distintos al tamaño poblacional: la ganancia de decodificación conservadora (0.25), la ventana temporal (0.5s), y el ruido intrínseco del modelo estocástico.

2) **Distribución sesgada:** La distribución sesgada simula poblaciones con sobrerrepresentación de una dirección específica, común en registros con colocación subóptima de electrodos.

TABLE VII
DESEMPEÑO CON DISTRIBUCIÓN SESGADA (N=20 REPETICIONES).

N Neuronas	Error (m)	std	R^2	std
10	1.5451	0.2564	-0.1193	0.1610
25	1.4585	0.2676	-0.0170	0.1626
50	1.4676	0.1985	-0.0048	0.1135
100	1.4524	0.1188	0.0161	0.0650
200	1.4171	0.1083	0.0425	0.0616

Análisis de resultados:

- 1) **Degradación catastrófica del desempeño:** La distribución sesgada produjo errores de posición $3.3\times$ mayores que la distribución uniforme (1.417 m vs 0.426 m con 200 neuronas), demostrando que el sesgo direccional compromete severamente la capacidad de decodificación. Este resultado valida la hipótesis de que la cobertura balanceada del espacio direccional es fundamental para BCIs efectivos.
- 2) **Coficiente de determinación negativo:** Con poblaciones pequeñas (10–25 neuronas), el R^2 fue negativo (-0.119 y -0.017 respectivamente), indicando que el modelo sesgado predice peor que simplemente usar la media de las velocidades objetivo. Esto confirma que la concentración de direcciones preferidas alrededor de 0° no solo reduce precisión, sino que produce estimaciones sistemáticamente erróneas en direcciones ortogonales al sesgo.
- 3) **Mejora marginal con aumento poblacional:** A diferencia de la distribución uniforme donde aumentar de 10 a 200 neuronas redujo el error en 5.5%, la distribución

sesgada solo mejoró 8.3% (de 1.545 m a 1.417 m). Este resultado demuestra que agregar más neuronas con el mismo sesgo direccional no compensa la falta de cobertura isotrópica—el problema es arquitectónico, no de escala.

- 4) **Variabilidad persistentemente alta:** Incluso con 200 neuronas, la desviación estándar se mantuvo elevada (0.108 m) comparada con distribución uniforme (0.006 m), indicando que el desempeño es inconsistente entre repeticiones. Esta alta variabilidad se debe a que direcciones de movimiento perpendiculares al sesgo (90° y 270°) dependen de pocas neuronas con señal débil, amplificando el efecto del ruido de Poisson.

- 5) **Implicaciones para colocación de electrodos:** Estos resultados tienen relevancia clínica directa: un arreglo de electrodos que registre predominantemente neuronas con direcciones preferidas similares—como podría ocurrir con colocación subóptima o registros de una columna cortical única—producirá control deficiente independientemente del número de canales. La distribución espacial de electrodos es más crítica que la densidad de muestreo.

- 6) **Convergencia a desempeño límite deficiente:** Entre 100 y 200 neuronas, la mejora fue mínima ($\Delta\text{Error} = 0.035$ m, $\Delta R^2 = 0.026$), sugiriendo que el sistema alcanzó un límite de desempeño determinado por la arquitectura sesgada, no por el tamaño poblacional. Este “techo de rendimiento” contrasta marcadamente con la distribución uniforme, donde el límite es mucho más alto.

3) **Distribución agrupada:** La distribución agrupada representa organización modular con neuronas especializadas en direcciones cardinales.

TABLE VIII
DESEMPEÑO CON DISTRIBUCIÓN AGRUPADA (N=20 REPETICIONES).

N Neuronas	Error (m)	std	R^2	std
10	0.5167	0.0826	0.3552	0.0492
25	0.4464	0.0197	0.4376	0.0304
50	0.4488	0.0241	0.4623	0.0211
100	0.4326	0.0080	0.4755	0.0179
200	0.4303	0.0086	0.4819	0.0072

Análisis de resultados:

- 1) **Desempeño comparable a distribución uniforme:** La distribución agrupada alcanzó error de 0.430 m y R^2 de 0.482 con 200 neuronas, prácticamente idéntico a la distribución uniforme (0.426 m, $R^2 = 0.476$). Esta equivalencia demuestra que la cobertura del espacio direccional no requiere distribución continua—cuatro direcciones cardinales estratégicamente ubicadas son suficientes para decodificación bidimensional efectiva.
- 2) **Mayor error inicial con poblaciones pequeñas:** Con 10 neuronas, la distribución agrupada mostró error 14.6% mayor que la uniforme (0.517 m vs 0.451 m), indicando que las arquitecturas modulares requieren un número mínimo de neuronas por cluster para ser

efectivas. Con solo 2–3 neuronas por dirección cardinal, el ruido estocástico domina la señal en cada módulo.

- 3) **Convergencia rápida con aumento poblacional:** Entre 10 y 50 neuronas, el error disminuyó 13.1% (de 0.517 m a 0.449 m), mejora más pronunciada que en distribución uniforme (4.1% en el mismo rango). Esto sugiere que las arquitecturas agrupadas se benefician desproporcionadamente de las primeras adiciones neuronales, ya que cada neurona refuerza directamente uno de los cuatro vectores cardinales.
- 4) **Estabilidad comparable a distribución uniforme:** La desviación estándar con 200 neuronas (0.009 m) fue similar a la distribución uniforme (0.006 m), demostrando que la modularidad no compromete consistencia. Ambas arquitecturas balanceadas proporcionan predicciones estables y reproducibles entre repeticiones.
- 5) **Validación de organización modular cortical:** Los resultados apoyan la hipótesis de que la corteza motora real podría organizarse en módulos especializados por dirección (similar a las “columnas de orientación” en corteza visual) sin sacrificar eficiencia de codificación. Esta arquitectura simplifica la interpretación biológica y tiene implicaciones para diseño de electrodos multi-canal con agrupamiento espacial.
- 6) **Saturación en población similar:** Al igual que la distribución uniforme, los rendimientos decrecientes emergen alrededor de 100–200 neuronas (mejora de solo 0.5% entre 100 y 200 neuronas). Esto confirma que el límite de desempeño está determinado por parámetros del decodificador (ganancia conservadora, ventana temporal) más que por la arquitectura específica de direcciones preferidas, siempre que haya balance direccional.
- 7) **Implicación para diseño de arreglos de electrodos:** Los resultados sugieren que estrategias de muestreo enfocadas en cuatro regiones corticales asociadas con direcciones cardinales (anterior, posterior, medial, lateral) podrían ser tan efectivas como muestreo uniforme distribuido, potencialmente simplificando procedimientos quirúrgicos y reduciendo invasividad.

C. Análisis Comparativo de Distribuciones

La evaluación sistemática de tres arquitecturas neuronales revela principios fundamentales para diseño de BCIs:




Fig. 3. Efecto del tamaño poblacional sobre el desempeño del decodificador. Error medio de posición disminuye con más neuronas en distribuciones balanceadas pero se mantiene elevado en distribución sesgada independientemente del tamaño poblacional.

1) Supremacía de cobertura balanceada sobre tamaño poblacional:

TABLE IX
COMPARACIÓN DE ARQUITECTURAS CON 200 NEURONAS.

Distribución	Error (200N)	R^2 (200N)	Mejora vs 10N
Uniforme	0.426 ± 0.006	0.476	5.5%
Sesgada	1.417 ± 0.108	0.043	8.3%
Agrupada	0.430 ± 0.009	0.482	16.7%

La distribución sesgada con 200 neuronas produce ERROR 3.3× MAYOR que distribución uniforme con solo 10 neuronas (1.417 m vs 0.451 m), demostrando que la cobertura isotrópica domina sobre el número absoluto de neuronas.

- 2) **Equivalencia de distribución discreta vs continua:** Distribuciones uniforme y agrupada alcanzaron desempeño prácticamente idéntico (diferencia < 1%), validando que cuatro direcciones cardinales son suficientes para control 2D. Este hallazgo tiene implicaciones prácticas: arreglos de electrodos con cuatro clusters estratégicamente ubicados pueden igualar el desempeño de muestreo uniforme denso.
- 3) **Falla de compensación por escalamiento:** Aumentar población de 10 a 200 neuronas (20× más) en distribución sesgada solo mejoró el error 8.3%, mientras que la misma expansión en distribución uniforme mejoró 5.5% pero desde una base 3× mejor. Esto confirma que el sesgo direccional es un defecto arquitectónico fundamental que no se resuelve agregando más neuronas con el mismo sesgo.
- 4) **Consistencia como indicador de calidad arquitectónica:** La desviación estándar del error con 200 neuronas fue:

- Uniforme: 0.006 m (variabilidad 1.4%)
- Agrupada: 0.009 m (variabilidad 2.1%)
- Sesgada: 0.108 m (variabilidad 7.6%)

Arquitecturas balanceadas (uniforme/agrupada) produjeron desempeño 5–10× más consistente que sesgada, crítico para aplicaciones clínicas donde confiabilidad predecible es esencial.

- 5) **Punto de saturación universal:** Tanto distribución uniforme como agrupada mostraron rendimientos decrecientes marcados más allá de 100 neuronas (mejora < 1% de 100 a 200), mientras distribución sesgada nunca alcanzó desempeño aceptable. Este resultado confirma que 100–200 neuronas bien distribuidas representan el punto óptimo costo-beneficio para BCIs bidimensionales con estos parámetros de decodificación.

VIII. CONCLUSIONES

A. Resultados Principales

El presente trabajo desarrolló exitosamente un simulador computacional de interfaces cerebro-computadora que implementa el algoritmo de vectores poblacionales de Georgopoulos [2], validando principios fundamentales de codificación neuronal mediante modelado estocástico de Poisson y análisis paramétrico sistemático.

Los resultados experimentales revelaron tres hallazgos centrales: **Primero**, la selección apropiada de parámetros del sistema es tan crítica como el tamaño poblacional. La configuración optimizada ($r_0=20$ Hz, $k=10$, ganancia=0.25, ventana=0.5s, $\alpha=0.5$) priorizó estabilidad sobre desempeño numérico absoluto, ilustrando que el comportamiento cualitativo es más valioso que la optimización de métricas aisladas. **Segundo**, la distribución espacial de direcciones preferidas impacta el desempeño más significativamente que el tamaño poblacional: la distribución uniforme proporcionó error=0.426 m ($R^2=0.476$ con 200 neuronas), mientras que la sesgada mostró degradación catastrófica (error=1.417 m, $R^2=0.043$) con el mismo número de neuronas—un deterioro de 3.3×. **Tercero**, se observaron rendimientos decrecientes más allá de 100–200 neuronas (mejora de apenas 0.2% entre 100 y 200), validando reportes de Serruya et al. [4] sobre control efectivo con poblaciones pequeñas.

B. Contribuciones

Este proyecto aporta: (1) validación computacional sistemática del algoritmo de Georgopoulos mediante 930 simulaciones independientes, (2) caracterización paramétrica exhaustiva identificando configuraciones óptimas, (3) primera evaluación cuantitativa del impacto de tres distribuciones direccionales sobre decodificación, y (4) plataforma educativa accesible en Python para explorar principios de codificación poblacional.

C. Implicaciones Prácticas

Los hallazgos tienen implicaciones directas para diseño de BCIs reales: la distribución espacial de electrodos es más crítica que la densidad de muestreo, arreglos con cobertura balanceada de cuatro regiones corticales pueden igualar configuraciones más densas, y poblaciones de 50–100 neuronas bien distribuidas son suficientes para control bidimensional básico.

La calibración conservadora de parámetros (ganancia=0.25) demostró ser superior a valores numéricamente óptimos por mayor estabilidad y consistencia.

D. Limitaciones

El trabajo presenta limitaciones: (1) modelo neuronal simplificado que no captura correlaciones entre neuronas ni adaptación de tasas, (2) tarea de control simplificada (trayectorias circulares a velocidad constante), (3) ausencia de plasticidad neuronal y aprendizaje del operador, (4) validación puramente computacional sin datos neurofisiológicos reales, y (5) enfoque limitado a control bidimensional.

E. Trabajo Futuro

Direcciones prometedoras incluyen: comparar con algoritmos modernos (filtros de Kalman [9], redes neuronales recurrentes), incorporar no-estacionariedades y recalibración, extender a control 3D con manipulación, validar con datos neurofisiológicos reales, desarrollar interfaz educativa interactiva, y optimizar arreglos de electrodos sistemáticamente.

El simulador valida exitosamente los principios de Georgopoulos, demostrando que la implementación sistemática de algoritmos establecidos constituye investigación ingenieril legítima a nivel de pregrado. Este proyecto ilustra el valor del modelado computacional para comprender sistemas biológicos complejos: mediante abstracciones simplificadas pero bien fundamentadas, es posible capturar principios esenciales y desarrollar intuición sobre factores que determinan el desempeño de sistemas reales.

REFERENCES

- [1] A. P. Georgopoulos, J. F. Kalaska, R. Caminiti, and J. T. Massey, "On the relations between the direction of two-dimensional arm movements and cell discharge in primate motor cortex," *Journal of Neuroscience*, vol. 2, no. 11, pp. 1527–1537, 1982.
- [2] A. P. Georgopoulos, A. B. Schwartz, and R. E. Kettner, "Neuronal population coding of movement direction," *Science*, vol. 233, no. 4771, pp. 1416–1419, 1986.
- [3] A. B. Schwartz, "Direct cortical representation of drawing," *Science*, vol. 265, no. 5171, pp. 540–542, 1994.
- [4] M. D. Serruya, N. G. Hatsopoulos, L. Paninski, M. R. Fellows, and J. P. Donoghue, "Instant neural control of a movement signal," *Nature*, vol. 416, no. 6877, pp. 141–142, 2002.
- [5] W. R. Softky and C. Koch, "The highly irregular firing of cortical cells is inconsistent with temporal integration of random EPSPs," *Journal of Neuroscience*, vol. 13, no. 1, pp. 334–350, 1993.
- [6] J. R. Wolpaw, N. Birbaumer, D. J. McFarland, G. Pfurtscheller, and T. M. Vaughan, "Brain-computer interfaces for communication and control," *Clinical Neurophysiology*, vol. 113, no. 6, pp. 767–791, 2002.
- [7] L. R. Hochberg, D. Bacher, B. Jarosiewicz, N. Y. Masse, J. D. Simeral, J. Vogel, S. Haddadin, J. Liu, S. S. Cash, P. van der Smagt, and J. P. Donoghue, "Reach and grasp by people with tetraplegia using a neurally controlled robotic arm," *Nature*, vol. 485, no. 7398, pp. 372–375, 2012.
- [8] J. L. Collinger, B. Wodlinger, J. E. Downey, W. Wang, E. C. Tyler-Kabara, D. J. Weber, A. J. McMorland, M. Velliste, M. L. Boninger, and A. B. Schwartz, "High-performance neuroprosthetic control by an individual with tetraplegia," *The Lancet*, vol. 381, no. 9866, pp. 557–564, 2013.
- [9] W. Wu, Y. Gao, E. Bienenstock, J. P. Donoghue, and M. J. Black, "Bayesian population decoding of motor cortical activity using a Kalman filter," *Neural Computation*, vol. 18, no. 1, pp. 80–118, 2006.
- [10] M. M. Churchland, J. P. Cunningham, M. T. Kaufman, J. D. Foster, P. Nuyujukian, S. I. Ryu, and K. V. Shenoy, "Neural population dynamics during reaching," *Nature*, vol. 487, no. 7405, pp. 51–56, 2012.

- [11] P. Dayan and L. F. Abbott, *Theoretical Neuroscience: Computational and Mathematical Modeling of Neural Systems*. Cambridge, MA: MIT Press, 2001.
- [12] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, and others, "Array programming with NumPy," *Nature*, vol. 585, no. 7825, pp. 357–362, 2020.